#### LOG 2810: Structures discrètes

Module: Théorie des Langages

Julien Dompierre, Philippe Galinier, Robert Roy Mis à jour par John Mullins, Fayçal Abouzaid et Foutse Khomh

Ecole Polytechnique de Montréal

### Liste des Chapitres

1.	Langages et grammaires	. 3
	Grammaires et Hiérarchie de Chomsky	
3.	Machine à états finis avec sortie	17
4.	Automates à états finis	48
5.	Gammaires régulières	69

#### Grammaires

#### Langages et grammaires

Chapitre .1 Langage naturel, langage formel (3)

- Langage naturel (4)
- Langage formel (5)

#### Chapitre .2 Grammaires - Hiérarchie de Chomsky (10)

- Vocabulaire, alphabet, symbole, mot, longueur, concaténation, chaîne vide (6)
- Grammaire syntagmatique (7)
- Mots dérivables (8) Langage de G (9)
- Grammaire de type 0 (12) Grammaire de type 1 (13)
- Grammaire de type 2 (14) Grammaire de type 3 (15)

### Définition: le langage naturel

La **syntaxe**: règles qui président à l'ordre des mots et à la construction des phrases dans une langue.

La **sémantique**: étude du langage considéré du point de vue du sens.

Un **langage naturel** est une langue comme le français ou le tagalog.

La syntaxe d'un langage naturel est extrêmement complexe et en fait il ne semble pas possible de préciser toutes les règles syntaxiques.

### Définition: le langage formel

Le **langage formel**, contrairement au langage naturel, est défini par un ensemble spécifique de règles de syntaxe.

La grammaire est une liste de règles de syntaxe qui permet, d'une part, de déterminer si une combinaison de mots constitue une phrase valide, et d'autre part, de créer des phrases valides dans un langage formel.

#### Définitions de base

Un vocabulaire (ou alphabet) V est un ensemble fini non vide d'éléments appelés des symboles.

Un **mot** dans V est une chaîne de longueur finie d'éléments de V. La **longueur** l(w) d'un mot w est le nombre d'éléments de V que contient le mot.

La **concaténation** des mots  $w_0$  et  $w_1$  est le mot w formé des éléments de  $w_0$  suivit des éléments du  $w_1$ .

La **chaîne vide**, notée  $\epsilon$ , est la chaîne qui ne contient aucun symbole.

L'ensemble de tous les mots dans V est noté  $V^*$ .

Un langage dans V est un sous-ensemble de  $V^*$ .

### Grammaire syntagmatique

Une grammaire syntagmatique G = (V, T, S, P) est constituée d'un vocabulaire V, d'un sous-ensemble T de symboles terminaux, d'un symbole de départ S de V (axiome) et d'un ensemble P de règles de  $(V^* \to V^*)$  de production.

L'ensemble V-T est noté N. Les éléments de N sont appelés les **symboles non terminaux**.

Une production est notée  $w_0 \to w_1$ , où  $w_0, w_1 \in V^*$  et  $w_0$  contient au moins un non terminal.

#### Définition: mots dérivables

Soit G = (V, T, S, P) une grammaire syntagmatique. Soit  $w_0 = lz_0r$  et  $w_1 = lz_1r$  des chaînes dans V. Si  $z_0 \to z_1$  est une production de G, on dit que  $w_1$  est **directement dérivable** à partir de  $w_0$  et on écrit  $w_0 \Rightarrow w_1$ .

Si  $w_0, w_1, ..., w_n$  où  $n \ge 1$ , sont des chaînes dans V telles que  $w_0 \Rightarrow w_1, w_1 \Rightarrow w_2, ..., w_{n-1} \Rightarrow w_n$ , alors on dit que  $w_n$  est dérivable à partir de  $w_0$  et on écrit

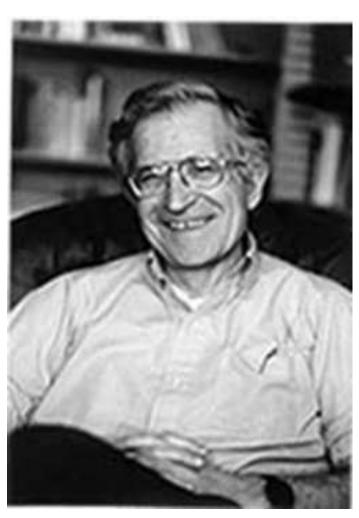
 $w_0 \Rightarrow w_n$ . La suite des étapes utilisées pour obtenir  $w_n$  à partir de  $w_0$  s'appelle une **dérivation**.

### Définition: langage de G

Soit G = (V, T, S, P) une grammaire syntagmatique. Le **langage créé à partir de** G (ou le **langage de** G), noté L(G), est l'ensemble de toutes les chaînes de terminaux qui sont dérivables à partir de l'axiome S. En d'autres mots,

$$L(G) = \{ w \in T^* \mid S \stackrel{*}{\Rightarrow} w \}.$$

#### Note historique: Noam Chomsky



Né le 7 décembre 1928 à Philadelphie.

MIT Linguistics and Philosophy, 77 Massachusetts Avenue Bldg. 32-D808 Cambridge, MA 02139 USA. chomsky@mit.edu

web.mit.edu/linguistics/www/
chomsky.home.html

### Hiérarchie de Chomsky

Chomsky a réalisé une une classification naturelle des langages décrits par les grammaires formelles, dite "La hiérarchie de Chomsky".

- 1. grammaire de type 0 : Grammaires généralisées
- 2. grammaire de type 1 : Grammaires contextuelles
- 3. grammaire de type 2 : Grammaires hors-contexte
- 4. grammaire de type 3 : Grammaires régulières

Une grammaire de **type 0** n'a aucune restriction quant à ses productions.

Les grammaires de type 0 sont appelées des grammaires récursivement énumérables ou grammaires généralisées

Une grammaire de **type 1** ne peut que comporter des productions ayant la forme  $w_1 \to w_2$ , où la longueur de  $w_2$  est plus grande que ou égale à la longueur de  $w_1$ , ou de la forme  $w_1 \to \epsilon$ .

Lorsqu'il y a production de la forme  $lw_1r \rightarrow lw_2r$  (mais pas de la forme  $w_1 \rightarrow w_2$ , la grammaire est de type 1, ou **contextuelle** puisqu'on peut remplacer  $w_1$  par  $w_2$  uniquement lorsqu'il est entouré des chaînes l et r.

Une grammaire de **type 2** peut avoir des productions ayant la forme  $w_1 \rightarrow w_2$  seulement, où  $w_1$  est un symbole unique qui n'est pas un symbole terminal.

Les grammaires de type 2 sont appelées des grammaires algébriques ou grammaires hors contexte (GHC) (ou non contextuelle, ou libre de contexte) puisqu'on peut remplacer un symbole non terminal, qui est le côté gauche de la production, dans une chaîne lorsqu'il apparaît, peu importe ce qui se trouve dans la chaîne.

Un langage créé par une grammaire de type 2 est appelé un **langage algébrique**.

Une grammaire de **type 3** peut uniquement comprendre des productions ayant la forme  $w_1 \rightarrow w_2$  avec  $w_1 = A$  et  $w_2 = aB$  ou  $w_2 = a$ , où A et B sont des symboles non terminaux et a est un symbole terminal, ou avec  $w_1 = S$  et  $w_2 = \epsilon$ .

Les grammaires de type 3 sont appelées des **grammaires régulières**. Les langages produits par une grammaire régulière sont **réguliers**.

### Types de grammaires

Type	Restrictions sur les productions $w_1 \rightarrow w_2$
	Aucune restriction
1	$l(w_1) \leq l(w_2)$ ou bien $w_1 \to \epsilon$ .
2	$w_1 = A$ , où $A$ est un symbole non terminal
3	$w_1 = A \text{ et } w_2 = aB \text{ ou } w_2 = a,$ $où A \in N, B \in N \text{ et } a \in T \text{ ou } S \to \epsilon$
	où $A \in N$ , $B \in N$ et $a \in T$ ou $S \to \epsilon$

Toute grammaire de type 3 est une grammaire de type 2, toute grammaire de type 2 est une grammaire de type 1 et toute grammaire de type 1 est une grammaire de type 0.

#### **Module**

#### Machines à états finis avec sortie

#### Chapitre .1 Table et diagramme d'états (18)

• Modélisation d'un distributeur automatique (18)

#### Chapitre .2 Machine de Mealy (22)

- Machine à états finis avec sorties (23)
- Table d'états (27) Diagramme d'états (29)
- Chaîne de sortie produite par un machine (32)
- Retardateur (35) Addition binaire (36)
- Langage reconnu (37)

#### Chapitre .3 Machine de Moore (39)

• Conversion Moore-Mealy (43) • Conversion Mealy-Moore (46)

# Modélisation d'un distributeur automatique



Le prix d'une boisson est de 30 cents. On peut mettre des pièces de 5 cents, 10 cents ou 25 cents. Si on met plus de 30 cents, la machine garde 30 cents et rend la monnaie. On peut appuyer sur le bouton 1 pour obtenir un Coca-Cola ou sur la bouton 2 pour obtenir un Pepsi. La machine ne plante pas et ne peut pas être rebootée!

# Modélisation d'un distributeur automatique

L'ensemble des entrées possibles I de la machine sont  $5\not\in$ ,  $10\not\in$ ,  $25\not\in$ , bouton B1 et bouton B2.

L'ensemble des sorties possibles O de la machine sont rien (n),  $5 \not c$ ,  $10 \not c$ ,  $15 \not c$ ,  $20 \not c$ ,  $25 \not c$ , un Coca-Cola C ou un Pepsi P.

La machine doit conserver en mémoire la somme d'argent déposée jusqu'à maintenant. Les états possibles S de sa mémoire sont  $0 \not e$ ,  $5 \not e$ ,  $10 \not e$ ,  $15 \not e$ ,  $20 \not e$ ,  $25 \not e$  et  $30 \not e$ . Ces états sont notés  $s_0, s_1, ..., s_6$  respectivement.

## Fonction de transition pour un distributeur

Dans quel état se trouve la machine en fonction de l'entrée.

État	État suivant									
		Entrée								
	5	10	25	B1	B2					
$s_0 (0 \not c)$	$s_1$	$s_2$	$S_5$	$s_0$	$s_0$					
$s_1 (5 \cancel{e})$	$s_2$	$s_3$	$s_6$	$s_1$	$s_1$					
$s_2$ (10¢)	$s_3$	$S_4$	$s_6$	$s_2$	$s_2$					
$s_3$ (15¢)	$S_4$	$S_5$	$s_6$	$S_3$	$s_3$					
$s_4 (20 \not c)$	$S_5$	$s_6$	$s_6$	$s_4$	$s_4$					
$s_5$ (25¢)	$s_6$	$s_6$	$s_6$	$S_5$	$S_5$					
$s_6 (30 \not e)$	$s_6$	$s_6$	$s_6$	$s_0$	$s_0$					

### Fonction de sortie pour un distributeur

Que retourne la machine en fonction de l'entrée.

État	Sortie							
			Entre	ée				
	5	10	25	B1	B2			
$s_0 (0 \not c)$	n	n	n	n	n			
$s_1 (5 \cancel{c})$	$\mid n \mid$	n	n	n	n			
$s_2$ (10¢)	$\mid n \mid$	n	5	n	n			
$s_3$ (15¢)	$\mid n \mid$	n	10	n	n			
$s_4 (20 \cancel{c})$	$\mid n \mid$	n	15	n	n			
$s_5$ (25¢)	$\mid n \mid$	5	20	n	n			
$s_6 (30 \not c)$	5	10	25	C	P			

# Note historique: George H. Mealy

Il travaillait chez Bell Labs et a publié "A Method for Synthesizing Sequential Circuits", Bell System Tech. J. vol 34, pp. 1045 à1079, septembre 1955.

## Définition: machine à états finis avec sorties

Une machine à états finis  $M=(S,I,O,f,g,s_0)$  est constituée

- d'un ensemble fini d'états S,
- d'un **alphabet d'entrée** fini *I*,
- d'un alphabet de sortie fini O,
- d'une fonction de transition  $f: S \times I \to S$  qui attribue un nouvel état à chaque couple (état, entrée),
- d'une fonction de sortie  $g: S \times I \rightarrow O$  qui attribue une sortie à chaque couple (état, entrée),
- d'un état initial  $s_0$ .
- Ces machines sont appelées machines de Mealy.

# Modélisation d'un distributeur automatique

Un distributeur de boissons gazeuses est une machine à états finis  $M=(S,I,O,f,g,s_0)$  où

• 
$$S = \{s_0, s_1, s_2, s_3, s_4, s_5, s_6\},$$

• 
$$I = \{5, 10, 25, B1, B2\},\$$

• 
$$O = \{n, 5, 10, 15, 20, 25, C, P\},\$$

- l'état initial est  $s_0$ ,
- suite, les deux transparents suivants...

# Modélisation d'un distributeur automatique (suite)

Un distributeur de boissons gazeuses est une machine à états finis  $M = (S, I, O, f, g, s_0)$  où

- $f: S \times I \rightarrow S$  est une fonction qui attribue un nouvel état à chaque couple (état, entrée),
- suite, transparent suivant...

$\overline{S}$	$f: S \times I \to S$										
		I									
	5	10	25	B1	B2						
$s_0$	$s_1$	$s_2$	$S_5$	$s_0$	$s_0$						
$s_1$	$s_2$	$s_3$	$s_6$	$s_1$	$s_1$						
$S_2$	$s_3$	$S_4$	$s_6$	$s_2$	$s_2$						
$s_3$	$s_4$	$S_5$	$s_6$	$s_3$	$s_3$						
$S_4$	$S_5$	$s_6$	$s_6$	$S_4$	$S_4$						
$S_5$	$s_6$	$s_6$	$s_6$	$S_5$	$S_5$						
$s_6$	$s_6$	$s_6$	$s_6$	$s_0$	$s_0$						

# Modélisation d'un distributeur automatique (fin)

Un distributeur de boissons gazeuses est une machine à états finis  $M = (S, I, O, f, g, s_0)$  où

•  $g: S \times I \rightarrow O$  est une fonction qui attribue une sortie à chaque couple (état, entrée).

$\overline{S}$	$g: S \times I \to O$										
		I									
	5	10	25	B1	B2						
$s_0$	$\mid n \mid$	n	n	n	n						
$s_1$	$\mid n \mid$	n	n	n	n						
$S_2$	$\mid n \mid$	n	5	n	n						
$s_3$	$\mid n \mid$	n	10	n	n						
$S_4$	$\mid n \mid$	n	15	n	n						
$S_5$	$\mid n \mid$	5	20	n	n						
$s_6$	5	10	25	C	P						

#### Définition: table d'états

Soit  $M = (S, I, O, f, g, s_0)$  une machine à états finis. On peut utiliser une **table d'états** (ou **table de transition d'états**) pour représenter les valeurs de la fonction de transition f et de la fonction de sortie g pour tous les couples d'états et d'entrée.

### Table d'états pour le distributeur automatique


$\overline{S}$		f: S	$S \times I$	$I \to \mathcal{L}$	S	$g: S \times I \to O$					
			I				I				
	15	10	25	B1	B2	5	10	25	B1	B2	
$s_0$	$s_1$	$s_2$	$S_5$	$s_0$	$s_0$	$\mid n \mid$	n	n	n	n	
$s_1$	$s_2$	$s_3$	$s_6$	$s_1$		$\mid n \mid$	n	n	n	n	
$s_2$	$s_3$	$s_4$	$s_6$	$s_2$	$s_2$	$\mid n \mid$	n	5	n	n	
$s_3$	$S_4$	$S_5$	$s_6$	$s_3$	$s_3$	$\mid n \mid$	n	10	n	n	
$s_4$	$S_5$	$s_6$	$s_6$	$S_4$	$s_4$	$\mid n \mid$	n	15	n	n	
$S_5$	$s_6$	$s_6$	$s_6$	$S_5$	$S_5$	$\mid n \mid$	5	20	n	n	
$s_6$	$s_6$	$s_6$	$s_6$	$s_0$	$s_0$	5	10	25	C	P	

### Définition: diagramme d'états

Soit  $M = (S, I, O, f, g, s_0)$  une machine à états finis. On peut la représenter en utilisant un **diagramme d'états**, qui est un graphe orienté avec arcs étiquetés. Dans de diagramme,


- chaque état est représenté par un cercle.
- chaque transition entre deux états est représentée par un arc orienté et étiqueté,
- chaque étiquette est une paire (valeur d'entrée, valeur de sortie).

### Diagramme d'états pour le distributeur automatique



### Exemple table d'états – diagramme d'états

$\overline{S}$	ا	f	g		
	د -	I .		I .	
	0	1	0	1	
$s_0$	$s_1$	$s_0$	1	0	
$s_1$	$s_3$	$s_0$	1	1	
$s_2$	$s_1$	$s_2$	0	1	
$S_3$	$s_2$	$s_1$	0	0	



# Chaîne de sortie produite par une machine

Une chaîne d'entrée fait passer l'état de départ par une suite d'états qui sont déterminés par la fonction de transition. A la lecture de la chaîne d'entrée, symbole par symbole de gauche à droite, chaque symbole d'entrée fait passer la machine d'un état à un autre, puisque chaque transition produit une sortie, toute chaîne d'entrée produit une chaîne de sortie.


# Chaîne de sortie produite par une machine

On suppose que la chaîne d'entrée est  $x = x_1 x_2 \cdots x_k$ . Alors, la lecture de cette entrée fait passer la machine de l'état  $s_0$  à l'état  $s_1$  où  $s_1 = f(s_0, x_1)$ , puis à l'état  $s_2$  où  $s_2 = f(s_1, x_2)$ , et ainsi de suite, ce parcours se terminant à l'état  $s_k$  où  $s_k = f(s_{k-1}, x_k)$ . Cette suite de transitions produit la chaîne de sortie  $y = y_1 y_2 \cdots y_k$  où  $y_1 = g(s_0, x_1)$  est la sortie correspondant à la transition de  $s_0$  à  $s_1$ ,  $y_2 = g(s_1, x_2)$ est la sortie correspondant à la transition de  $s_1$  à  $s_2$  et ainsi de suite.

On peut étendre la définition de la fonction de sortie g pour qu'elle s'applique aux chaînes d'entrée de telle sorte que g(x) = y où y est la chaîne produite correspondant à la chaîne d'entrée x.

## Exemple de sortie produite par un machine

$\overline{S}$	j	f	(	<b>J</b>
	0	<i>I</i> 1	0	1
$\overline{s_0}$	$s_1$	$s_0$	1	0
$s_1$	$s_3$	$s_0$	1	1
$s_2$	$s_1$	$s_2$	0	1
$S_3$	$s_2$	$s_1$	0	0




I																	
$\overline{S}$	$s_0$		$s_0$		$s_0$		$s_1$		$s_0$		$s_0$		$s_1$		$s_0$		$s_0$
$\overline{O}$		$\overline{\cap}$		$\overline{\cap}$		1		1		$\overline{0}$		1		1		$\overline{\cap}$	


### Exemple de machine de Mealy: le retardateur

Le retardateur transforme la chaîne binaire  $x_1x_2\cdots x_k$  en la chaîne  $0x_1x_2\cdots x_{k-1}$ . La machine est à l'état  $s_1$  si l'entrée précédente était 1 et à l'état  $s_2$  si l'entrée précédente était 0.

$\overline{S}$	J	f	(	9
	0	<i>I</i> 1	$\begin{bmatrix} 0 \end{bmatrix}$	<i>I</i> 1
$\overline{s_0}$	$s_2$	$\overline{s_1}$	0	0
$s_1$	$s_2$	$s_1$	1	1
$S_2$	$s_2$	$s_1$	0	0



# Exemple de machine de Mealy: addition binaire




S		J	f		g				
		ا.	I		$\begin{bmatrix} 00 & 01 & 10 & 11 \end{bmatrix}$				
	00	01	10	11	00	01	10	11	
$s_0$	$s_0$	$s_0$	$s_0$	$s_1$	0	1	1	0	
$s_1$	$s_0$	$s_1$	$s_1$	$s_1$	1	0	0	1	

## Exemple de machine qui reconnaît un langage

On veut une machine à états finis qui produit un 1 comme bit de sortie si et seulement si les trois derniers bits reçus sont tous des 1. Cette machine reconnaît un langage car elle produit 1 si et seulement si la chaîne d'entrée admet une propriété spécifique.

L'état  $s_0$  se souvient que l'entrée précédente n'était pas un 1. L'état  $s_1$  se souvient que l'entrée précédente était un 1, mais l'antépénultième entrée n'était pas un 1. L'état  $s_1$  se souvient que les deux entrées précédentes étaient des 1.

## Exemple de machine qui reconnaît un langage



# Note historique: Edward F. Moore

Edward F. Moore né le 23 novembre 1925 à Baltimore au Maryland et mort le 14 juin 2003 à Madison au Wisconsin.

Il travaillait chez Bell Labs et a publié "Gedanken-experiments on sequential machines", pp. 129-153 dans Shannon and McCarthy (éds.), Automata Studies, Annals of Mathematics Studies, Number 34, Princeton University Press, 1956.


#### Définition: machine de Moore

Une machine de Moore  $M = (S, I, O, f, g, s_0)$  est constituée

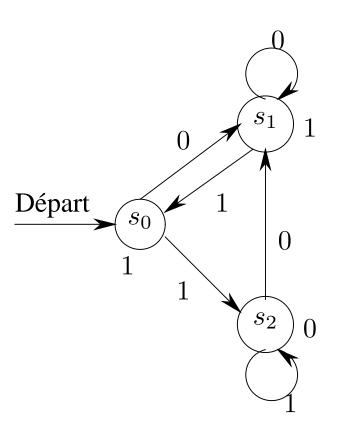
- d'un ensemble fini d'états S,
- d'un alphabet d'entrée fini *I*,
- d'un alphabet de sortie fini O,
- d'une fonction de transition  $f: S \times I \to S$  qui attribue un nouvel état à chaque couple (état, entrée),
- d'une fonction de sortie  $g: S \to O$  qui attribue une sortie à chaque état,
- d'un état initial  $s_0$ .

# table d'états – diagramme d'états

$\overline{S}$	f		g
	I		
	0	1	
$\overline{s_0}$	$s_0$	$S_2$	0
$s_1$	$s_3$	$s_0$	1
$s_2$	$s_2$	$s_1$	1
$S_3$	$s_2$	$s_0$	1



# diagramme d'états – table d'états



$\overline{S}$	f		g
	I		
	0	1	
$\overline{s_0}$	$s_1$	$S_2$	1
$s_1$	$s_1$	$s_0$	1
$S_2$	$s_1$	$s_2$	0

### **Conversion Moore-Mealy**

#### THÉORÈME:

Pour toute machine de Moore

 $M = (S, I, O, f, g, s_0)$ , il existe une machine de Mealy  $M' = (S', I', O', f', g', s'_0)$  qui possède les mêmes fonctionnements.

#### PREUVE:

On pose:

• 
$$I' = I, O' = O, S' = S \text{ et } s'_0 = s_0,$$


et f' vérifie : f'(q, e) = q' et s = g'(q) ssi f(q, e) = q' et s = g(q')

On prouve que tout fonctionnement de l'une est un fonctionnement de l'autre par récurrence sur la longueur des fonctionnements.

Un fonctionnement est le couple de mots  $(w_1w_2)$  tq  $w_1=e_1 \dots e_n$  des entrées qui produisent les sorties  $w_2=s_1 \dots s_n$  passage par les états.

### **Conversion Moore-Mealy**

Conversion d'une machine de Moore, sous forme de diagramme d'états, en une machine de Mealy.



### **Conversion Moore-Mealy**

Conversion d'une machine de Moore, sous forme de table d'états, en une machine de Mealy.

$\overline{S}$	f		g
	I		
	0	1	
$\overline{s_0}$	$s_1$	$S_2$	1
$s_1$	$s_1$	$s_0$	1
$S_2$	$s_1$	$s_2$	0

$\overline{S}$	f		(	J
	I			I
	0	1	0	1
$\overline{s_0}$	$s_1$	$s_2$	1	0
$s_1$	$s_1$	$s_0$	1	1
$s_2$	$s_1$	$S_2$	1	0

### **Conversion Mealy-Moore**

#### THÉORÈME:

Pour toute machine de Mealy

 $M = (S, I, O, f, g, s_0)$ , il existe une machine de Moore  $M' = (S', I', O', f', g', s'_0)$  qui possède les mêmes fonctionnements.

#### PREUVE:

Si la machine de Mealy a N état, et P sorties, la machine de Moore aura au plus  $P\times N+1$  états .


Un état qui reçoit des transitions avec plus d'une sortie est 'splitté' en autant d'états que de sorties. On aura donc:

- $I' = I, O' = O, S' = S \times O \text{ et } s'_0 = s_0,$
- f'((q,s),e) = (q',s') et g'(q) = s ssi f(q,e) = q') et g'(q,e) = s'


Preuve de l'équivalence par récurrence sur la longueur des fonctionnements.

## Exemple de Conversion Mealy-Moore

Machine de Mealy



Machine de Moore équivalente



### Automates d'États Finis

#### Machines à états finis sans sortie

Chapitre .1 Ensemble de mots (49)

• Concaténation et puissance (49) • Fermeture de Kleene (51)

Chapitre .2 Automates finis déterministes (52)

• Machine à états finis sans sortie (52) • Langage reconnu (54)

Chapitre .3 Automates finis non déterministes (55)

• Langage reconnu (59) • Déterminisation d'un AFN (61)

Chapitre .4 Minimisation d'un Automate fini (66)

Chapitre .5 Limites des automates finis (83) • Lemme de pompage (84)

• Décidabilité (86)

# Définition: concaténation et puissance

DÉFINITION: concaténation

Soient A et B des sous-ensembles de  $V^*$ , où V est un vocabulaire. La **concaténation** de A et B, notée A.B, est l'ensemble de toutes les chaînes de la forme xy où x est une chaîne dans A et y est une chaîne dans B.

DÉFINITION: puissances de A

On définit récursivement  $A^n$  pour n=0,1,2,...

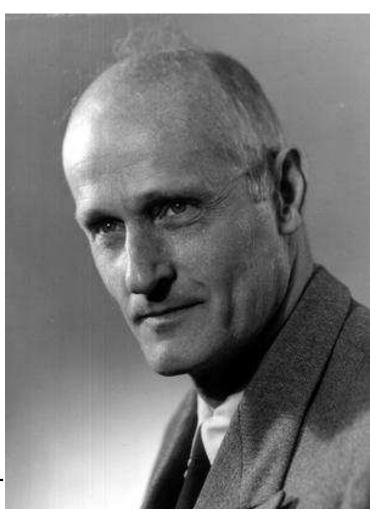
- $A^0 = \{\epsilon\}$
- $A^{n+1} = A^n.A$  pour n = 1, 2, 3, ....

# Note historique: Stephen Cole Kleene

Né le 5 janvier 1909 à Hartford, Connecticut. Mort le 25 janvier 1994 à Madison, Wisconsin

Kleene prononçait son nom de famille "klay'nee". "klee'nee" et "kleen" sont deux mauvaises prononciations très répandues.

math.library.wisc.ed kleene.htm



#### Définition: fermeture de Kleene

On suppose que A est un sous-ensemble de  $V^*$ . Alors, la **fermeture de Kleene** de A, notée  $A^*$ , est l'ensemble constitué des concaténations d'un nombre arbitraire de chaînes de A. Autrement dit,

$$A^* = \bigcup_{k=0}^{\infty} A^k.$$

# Définition: machine à états finis sans sortie

Une machine à états finis sans sortie, également appelée automate fini,

 $M = (S, I, f, s_0, F)$  est constituée


- d'un ensemble fini d'états S,
- d'un alphabet d'entrée fini I,
- d'une fonction de transition  $f: S \times I \to S$  qui attribue un état suivant à chaque couple (état, entrée),
- d'un état initial  $s_0$ ,
- $\bullet$  et d'un sous-ensemble F de S constitué d'états finaux.

On peut représenter un automate fini en utilisant soit des tables d'états, soit des diagrammes d'états. Les états finaux sont indiqués dans les diagrammes d'états par des cercles doubles.

# Table d'états - Diagramme d'états. Exemple.

Soit l'automate fini 
$$M = (S, I, f, s_0, F)$$
, où  $S = \{s_0, s_1, s_2, s_3\}, I = \{0, 1\}, F = \{s_0, s_3\}.$ 

	f	
S	I	
	0	1
$s_0$	$s_0$	$s_1$
$s_1$	$s_0$	$s_2$
$s_2$	$s_0$	$s_0$
$S_3$	$S_2$	$s_1$



### Définition: langage reconnu

On dit qu'une chaîne est **reconnue** ou **acceptée** par la machine  $M = (S, I, f, s_0, F)$  si elle fait passer l'état initial  $s_0$  à un état final, autrement dit si  $f(s_0, x)$  est un état dans F.

Le langage reconnu ou langage accepté par la machine M, noté L(M), est l'ensemble de toutes les chaînes qui sont reconnues par M.

Deux automates finis sont **équivalents** s'il reconnaissent le même langage.

## Automates finis déterministes et non déterministes. Exemples

Un automate fini est **déterministe** ou  $\hat{\mathbf{a}}$  **comportement déterminé**, si pour chaque couple (état, entrée), il y a un état suivant unique donné par la fonction de transition f.

Dans un automate fini **non déterministe**, il peut y avoir aucun, un ou plusieurs états suivants donnés par la fonction de transition f.

# Définition: automate fini non déterministe

#### Un automate fini non déterministe (AFN)


 $M = (S, I, f, s_0, F)$  est constitué

- d'un ensemble fini d'états S,
- d'un alphabet d'entrée fini I,
- d'une fonction de transition  $f: S \times I \to \mathcal{P}(S)$  qui attribue un *ensemble d'états* à chaque couple (état, entrée),
- d'un état initial  $s_0$ ,
- et d'un sous-ensemble F de S constitué d'états finaux.

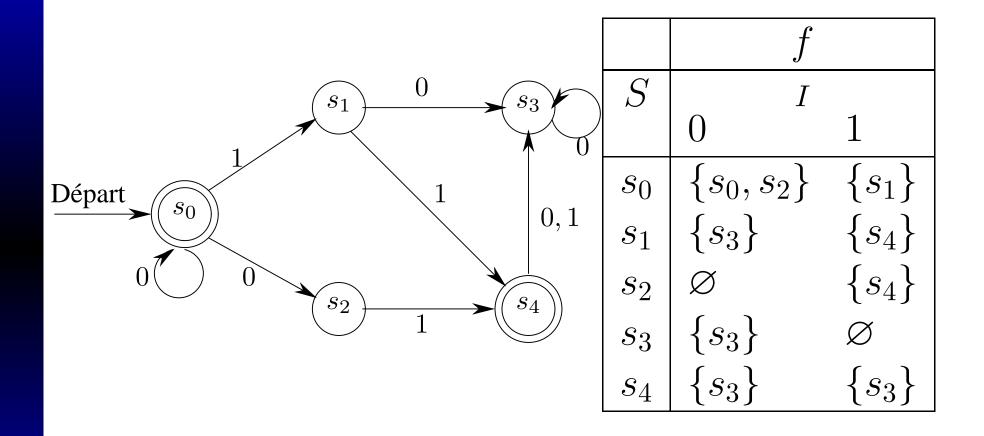
## Table et Diagramme d'états pour un AFN

Soit l'automate fini  $M = (S, I, f, s_0, F)$ , où  $S = \{s_0, s_1, s_2, s_3\}, I = \{0, 1\}, F = \{s_2, s_3\}.$ 

	f	
S	I	
	0	1
$s_0$	$\{s_0, s_1\}$	$\{s_3\}$
$s_1$	$\{s_0\}$	$\{s_1,s_3\}$
$s_2$	Ø	$\{s_0,s_2\}$
$S_3$	$\{s_0,s_1,s_2\}$	$\{s_1\}$



# Exemple diagramme d'états – table d'états



## Fonction de transition pour une chaîne

Que signifie pour un automate fini non déterministe le fait de reconnaître une chaîne?

Soit  $x=x_1x_2\cdots x_k$ , une chaîne dans  $I^*$ . Alors,  $f(s_1,x)$  est un ensemble d'états obtenu en utilisant chaque symbole successif de x, de gauche à droite, comme entrée en commençant par l'état  $s_1$ . À partir de  $s_1$ , on passe à un ensemble d'états  $S_2=f(s_1,x_1)$ , puis le symbole  $x_2$  fait passer chacun des états de  $S_2$  à un ensemble d'états. Soit  $S_3$  l'union de ces ensembles, ie,  $S_3=f(S_2,x_2)$ . On poursuit ce processus, en incluant à chaque étape tous les états obtenus en utilisant un état obtenu à l'étape précédente et le symbole d'entrée actuel.

#### Définition: langage reconnu

On dit que la chaîne x est **reconnue** ou **acceptée** par l'automate fini non déterministe  $M = (S, I, f, s_0, F)$  s'il y a un état final dans l'ensemble de tous les états qu'on peut obtenir à partir de  $s_0$  en consommant x.

Le **langage reconnu** ou **langage accepté** par la machine M, noté L(M), est l'ensemble de toutes les chaînes qui sont reconnues par M.

#### Déterminisation d'un AFN

Théorème: Si le langage L est reconnu par un automate fini non déterministe  $M_0$ , alors il existe un automate fini déterministe  $M_1$  qui reconnaît le même langage.

#### Autre formulation:

THÉORÈME: [Déterminisation]. Pour tout AFN  $M_0$  défini sur S, il existe un AFD  $M_1$  équivalent à  $M_0$ . Si  $M_0$  a n états, alors  $M_1$  a au plus  $2^n$  états.

#### Preuve par construction

On pose  $M_0 = (\Sigma, Q, I, F, \delta)$  et on considère  $M_1$  défini par  $M_1 = (\Sigma, 2^Q, \{I\}, F_1, \delta_1)$  avec :


- $F_1 = \{G \subset Q, F \cap G \neq \emptyset\}.$
- $\delta_1(G, a) = \bigcup_{q \in G} \delta(q, a)$

Les états de  $M_1$  sont donc associés de manière biunivoque à des sous-ensembles de Q.

- l'état initial est l'ensemble *I* ;
- chaque partie contenant un état final de  $M_0$  donne lieu à un état final de  $M_1$ ;
- la transition sortante d'un sous-ensemble E, étiquetée par a, atteint l'ensemble de tous les états de Q atteignables depuis un état de E par une transition étiquetée par a.
- $M_1$  est le déterminisé de  $M_0$ .

# Exemple déterminisation d'un AFN (1)

Soit l'automate suivant à déterminiser:



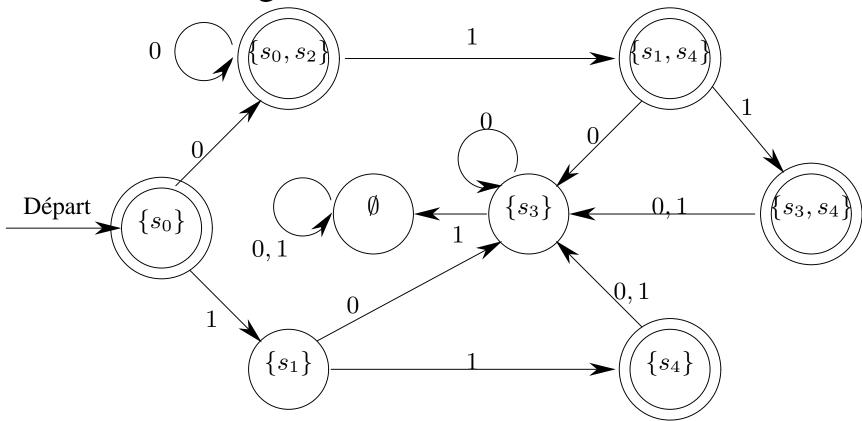
# Exemple déterminisation d'un AFN (2)

	f	
S	I	
	0	1
$s_0$	$\{s_0, s_2\}$	$\{s_1\}$
$s_1$	$\{s_3\}$	$\{s_4\}$
$s_2$	Ø	$\{s_4\}$
$s_3$	$\{s_3\}$	Ø
$S_4$	$\{s_3\}$	$\{s_3\}$

	f	
S	1	
	0	1
$s_0$	$\{s_0,s_2\}$	$\{s_1\}$
$s_1$	$\{s_3\}$	$\{s_4\}$
$s_2$	Ø	$\{s_4\}$
$s_3$	$\{s_3\}$	Ø
$s_4$	$\{s_3\}$	$\{s_3\}$
$s_0,s_2$	$\{s_0,s_2\}$	$\{s_1,s_4\}$
$s_1,s_4$	$\{s_3\}$	$\{s_3,s_4\}$
$s_3,s_4$	$\{s_3\}$	$\{s_3\}$

# Exemple déterminisation d'un AFN (3)

Résulat de la dégterminisation:



#### Automate fini minimal

DÉFINITION (Minimalité): Un automate  $A = (Q, \Sigma, \delta, q_0, F)$  est minimal si pour tout  $q, q' \in Q$ , il existe  $w \in L(q, A) \setminus L(q', A)$  (il n'y a pas deux états distincts qui acceptent le même langage).


Autrement dit, la minimalité porte sur le nombre d'états de l'automate.

# Minimisation d'un automate fini.

PRINCIPE : on définit des classes d'équivalence d'états par raffinements successifs. Chaque classe d'équivalence obtenue forme un seul même état du nouvel automate.

- 1. Faire deux classes : A contenant les états terminaux et B contenant les états non terminaux.
- 2. S'il existe un symbole a et deux états  $e_1$  et  $e_2$  d'une même classe tels que  $\delta(e_1, a)$  et  $\delta(e_2, a)$  n'appartiennent pas à la même classe, alors créer une nouvelle classe et séparer  $e_1$  et  $e_2$ .
- 3. Recommencer 2 jusqu'à ce qu'il n'y ait plus de classes à séparer.
- 4. Chaque classe restante forme un état du nouvel automate

# Exemple de minimisation d'un AF.



i	Ī	Ī
	X	y
0	1	3
1	0	2
2	0	0
3	0	4
4	0	5
5	0	0
'		

$$A = \{0\}, B = \{1, 2, 3, 4, 5\}$$

$$A = \{0\}, B = \{1, 3, 4\}, C = \{2, 5\}$$

$$A = \{0\}, B = \{1, 4\}, C = \{2, 5\}, D = \{3\}$$

	X	y
A	В	D
В	A	C
C	A	A
D	A	В

### Grammaires Régulières

#### Expressions et grammaires régulières

Chapitre .1 Expressions et ensembles réguliers (70)

• Expression régulière et Ensemble régulier (70)

Chapitre .2 Théorème de Kleene (71)

Chapitre .3 Grammaires régulières (77)

- Transformation grammaire régulière → automate fini (79)
- Transformation automate fini  $\rightarrow$  grammaire régulière (81)

## Définition: expression régulière

Les **expressions régulières** dans un ensemble I sont définies récursivement comme suit:

- Le symbole  $\varnothing$  est une expression régulière,
- le symbole  $\epsilon$  est une expression régulière,
- le symbole x est une expression régulière pour tout  $x \in I$ ,
- Si A et B sont des expressions régulières, alors (A.B),  $(A \cup B)$  et  $A^*$  sont des expressions régulières.

Les expressions régulières dénotent des ensembles appelés ensembles réguliers.

#### Théorème de Kleene

THÉORÈME DE KLEENE: Un ensemble est régulier si et seulement si cet ensemble est reconnu par un automate fini.

DÉMONSTRATION : Un ensemble régulier est défini en fonction des expressions régulières qui sont définies récursivement. On peut prouver que tout ensemble régulier est reconnu par un automate fini si on peut démontrer que

- 1.  $\emptyset$ ,  $\{\epsilon\}$  et  $\{a\}$  sont reconnus par un automate fini,
- 2. A.B et  $A \cup B$  sont reconnus par un automate fini si A et B le sont,
- 3.  $A^*$  est reconnu par un automate fini si A l'est.

On peut aisément construire tous ces automates ...

# Démonstration du théorème de Kleene (suite 1)

 $R\'{e}ciproquement$ : A partir d'un AFD A, on peut construire une ER qui dénote le langage reconnu par A.

Les systèmes d'équations linéaires à droite permettent de ramener le calcul d'une ER à la résolution d'un système d'équations.

- A chaque état q on associe une expression régulière  $Y_q$  dénotant le langage  $L_q(A)$  associé à cet état.  $Y_q$  décrit le langage des mots tels que  $\delta^*(q,w) \in F$  où  $\delta^*$  est le prolongement de  $\delta$  aux mots.
- On obtient un système d'équations dont les inconnues sont des ER dénotant des langages.
- Si q est l'état initial,  $Y_q$  décrit le langage reconnu par A.

# Démonstration du théorème de Kleene (suite 2)

Pour résoudre le système obtenu on procède par substitutions et en résolvant l'équation : Y = AY + B

•  $A^*B$  est bien solution :

$$A^*B = AA^*B + B = A^*B + B = A^*B$$

- $A^*B$  est une solution minimale : si Y est une solution, alors  $A^*B \subseteq Y$ Récurrence sur la hauteur d'étoile a:
  - si  $i = 0, A^0B = B \subseteq Y$  car Y = AY + B
  - hyp. réc. pour  $i = n : A^n B \subseteq Y$
  - pour  $n+1:A^{n+1}B=AA^nB\subseteq AY\subseteq AY+B=Y$ , cqfd.

adéfinie par induction structurelle  $(h(a) = h(\epsilon) = 0; h(e+f) = max(h(e), h(f)) = h(ef); h(e^*) = 1 + h(e))$ 

# Démonstration du théorème de Kleene(suite 3)

• si  $\epsilon \notin A$  alors  $A^*B$  est l'unique solution.

On suppose la non-unicité de la solution  $A^*B$ .

Soit X une autre solution et soit un mot w de longueur minimale tel que  $w \in X \backslash A^*B$ .

 $w \in X = AX + B$  et  $w \notin B$  donc w = uv avec  $u \in A$  et  $v \in X$ . Or  $v \notin A^*B$  donc  $v \notin X$   $A^*B$ .

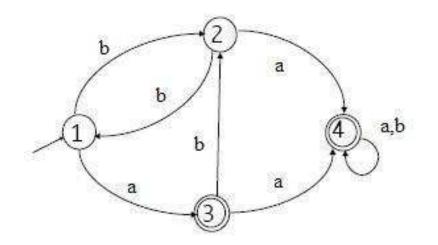
Contradiction : la longueur de w n'était donc pas minimale !

• si  $\epsilon \in A$  alors pour tout  $C \subseteq \Sigma^*, Y = A^*B + A^*C$  est aussi solution :

$$A^*B + A^*C = A(A^*B + A^*C) + B = A^*B + A^*C = A^*B + A^*C$$

• si l'automate de départ est déterministe, on a toujours :  $\epsilon \notin A$ 

### **Exemple**



$$\begin{cases} Y_1 &= bY_2 + aY_3 \\ Y_2 &= bY_1 + aY_4 \\ Y_3 &= \epsilon + aY_4 + bY_2 \\ Y_4 &= \epsilon + (a+b)Y_4 \end{cases}$$

$$Y_4 = (a+b)^*$$

$$\begin{cases} Y_1 = bY_2 + aY_3 \\ Y_2 = bY_1 + a(a+b)^* \\ Y_3 = \epsilon + a(a+b)^* + bY_2 \end{cases}$$

#### Exemple (suite)

$$\begin{cases} Y_1 &= bbY_1 + ba(a+b)^* + aY_3 \\ Y_3 &= \epsilon + a(a+b)^* + bbY_1 + ba(a+b)^* \\ \text{D'où} \\ \begin{cases} Y_1 &= bbY_1 + ba(a+b)^* + aY_3 \\ Y_3 &= \epsilon + bbY_1 + (b+\epsilon)a(a+b)^* \end{cases}$$

#### On en déduit:

$$Y_1 = bbY_1 + ba(a+b)^* + a\epsilon + abbY_1 + a(b+\epsilon)a(a+b)^*$$

#### **Finalement:**

$$Y_1 = (abb + bb)^* (ba(a+b)^* + a(\epsilon + (b+\epsilon)a(a+b)^*))$$

## Rappel: grammaire régulière

Une grammaire régulière (ou de type 3) G = (V, T, S, P) est constituée d'un vocabulaire V, d'un sous-ensemble T de V composé de terminaux, d'un axiome S de V et d'un ensemble de production P où chaque production a la forme:

- $S \rightarrow \epsilon$ ,
- $A \rightarrow a$ ,
- $A \rightarrow aB$ ,

où a est un symbole terminal et A et B sont des symboles non terminaux.

### Grammaire régulière, ensemble régulier et automate fini

THÉORÈME: Un ensemble est généré par une grammaire régulière si et seulement s'il constitue un ensemble régulier.

DÉMONSTRATION: en exercice

De ce théorème "grammaire régulière  $\Leftrightarrow$  ensemble régulier", du théorème de Kleene "ensemble régulier  $\Leftrightarrow$  automate fini", on obtient par transitivité "grammaire régulière  $\Leftrightarrow$  automate fini". Donc, si on a une grammaire régulière, alors il existe un automate fini que reconnaît le même langage, et vice-versa.

# Transformation grammaire rég. $\rightarrow$ automate fini

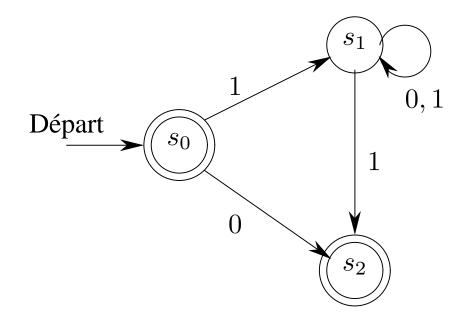
Soit G = (V, T, S, P) une grammaire régulière générant l'ensemble L(G). On cherche l'automate fini  $M = (S, I, f, s_0, F)$  qui reconnaît L(G).

- S contient un état  $s_A$  pour chaque symbole non terminal A de G.
- S contient un état additionnel  $s_F$  qui est un état final.
- L'état de départ  $s_0$  correspond au symbole de départ S.
- L'état  $s_0$  est un état final si  $S \to \epsilon$  est une production.
- Il y a une transition de  $s_A$  vers  $s_F$  à l'entrée de a si  $A \to a$  est une production.
- Il y a une transition de  $s_A$  vers  $s_B$  à l'entrée de a si  $A \to aB$  est une production.

# Transformation grammaire rég. $\rightarrow$ automate fini

Soit G=(V,T,S,P) où  $V=\{0,1,A,S\},\,T=\{0,1\}$  et les productions

- $S \rightarrow 1A$ ,
- $S \to 0$ ,
- $S \to \epsilon$ ,
- $A \rightarrow 0A$ ,
- $A \rightarrow 1A$ ,
- $A \rightarrow 1$ .



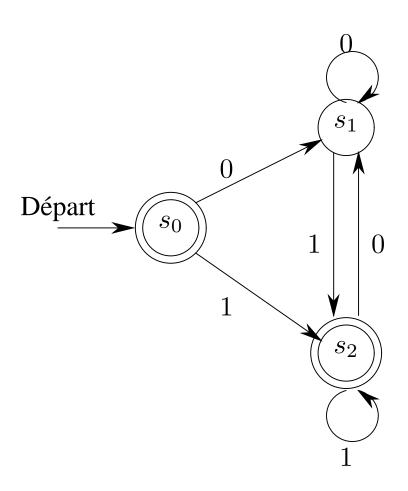
 $s_0$  correspond à S,  $s_1$  correspond à A et  $s_2$  correspond à l'état final.

# Transformation automate fini $\rightarrow$ grammaire rég.

Soit  $M = (S, I, f, s_0, F)$  un AFD qui reconnaît L(M). On cherche une grammaire régulière G = (V, T, S, P) qui génère L(M).

- V est formé en attribuant un symbole à chaque état de S et à chaque symbole de I.
- L'ensemble T des symboles terminaux correspond à I.
- Le symbole de départ S correspond à l'état de départ  $s_0$ .
- Si l'état s passe à un état final à l'entrée de a, alors  $A_s \to a$  est une production.
- Si l'état s passe à l'état t à l'entrée de a, alors  $A_s \to aA_t$  est une production.
- Si l'état de départ  $s_0$  est un état final, alors  $S \to \epsilon$  est une production.

# Transformation automate fini $\rightarrow$ grammaire rég.



G = (V, T, S, P) où  $V = \{A, B, S, 0, 1\}$ ,  $T = \{0, 1\}$ , S, A et B correspondent aux états  $s_0$ ,  $s_1$  et  $s_2$ , et P =

- $S \to 0A$ ,
- $S \to 1B$ ,
- $S \rightarrow 1$ ,
- $S \to \epsilon$ ,
- $A \rightarrow 0A$ ,
- $A \rightarrow 1B$ ,
- $A \rightarrow 1$ ,
- $B \to 0A$ ,
- $B \rightarrow 1B$ ,
- $\bullet$   $B \rightarrow 1.$

#### Limites des automates finis

Rappel: Un ensemble est reconnu par un automate fini si et seulement s'il est régulier.

On montre qu'il existe des ensembles qui ne sont pas réguliers en prouvant qu'ils ne sont pas reconnus par un automate fini.

Exemple: L'ensemble  $\{a^nb^n \mid n \in \mathbb{N}\}$  n'est pas régulier.

Voir la démonstration dans les slides suivants.

### Lemme de pompage

Soit L un langage régulier reconnu par un automate à p états. Soit z un mot de L de longueur  $\geq p$ . Alors z se factorise en z=uvw, où  $|uv|\leq p,\,v\neq\epsilon$  et, pour tout  $i\geq 0$ , on a  $uv^iw\in L$ .

#### **DÉMONSTRATION**

Si  $z=a_1a_2...a_m$  est accepté par un automate à p états et que  $m\geq p$ , le chemin correspondant à z dans l'automate passe deux fois par un même état (principe des tiroirs). Soit q le premier état qui est revisité. On a alors z=uvw, où  $\delta(q_0,u)=q$ , et  $\delta(q,v)=q$ . On a  $v\neq \epsilon$  et le chemin correspondant à uv visite l'état q deux fois et lui seul. Donc  $|uv|\leq p$ . Enfin,  $\delta(q_0,uv^i)=q$  donc  $\delta(q_0,uv^iw)=\delta(q_0,z)$  et finalement  $uv^iw\in L$ .

# Une application du lemme de pompage

Il est souvent utilisé pour démontrer qu'un langage donné n'est pas régulier. La preuve se fait en général par l'absurde, en supposant que le langage est régulier et en exhibant un mot du langage de longueur suffisante tel que la propriété  $uv^iw\in L$  ne soit pas vérifiée.

Exemple: Soit  $L=\{a^nb^n\}$  sur l'alphabet  $S=\{a,b\}$ . Supposons par l'absurde que L est régulier. Soit p l'entier apparaissant le lemme. On choisit le mot  $w=a^pb^p$ . Il existe donc une décomposition w=xyz vérifiant les conditions du lemme. |xy|< p donc il existe deux entiers i et j tels que i+j< p et  $x=a^i, y=a^j$ . De plus j>0 car y n'est pas le mot vide. Il en résulte que  $z=a^{p-i-j}b^p$ . On devrait ainsi avoir  $xz=xy^0z=a^{p-j}b^p\in L$ , ce qui est absurde car p-j< p. Donc L n'est pas régulier.

Le lemme est aussi vérifié pour de nombreux langages non-réguliers : il n'exprime donc qu'une condition nécessaire (mais pas suffisante).

#### Décidabilité

THÉORÈME: Les problèmes suivants sont décidables:

- 1. L'automate M reconnaît un langage non-vide;
- 2. L'automate M reconnaît un langage infini;
- 3. Le langage reconnu par M est inclus dans celui reconnu par N;
- 4. Les automates M et N reconnaissent le même langage.

DÉMONSTRATION: en exercice